

**TESINA: RICONOSCIMENTO DEI SEGNALE
STRADALI CON RETI NEURALI
CONVOLUZIONALI**

MARCO GORGONE

ANNO ACCADEMICO 2025/2026

DIPARTIMENTO DI FISICA – UNIVERSITÀ DEGLI STUDI DI TORINO

Indice

Abstract	3
Metodo	3
Risultati	4
Conclusions / Possible Future Developments	5

Abstract

Questo lavoro propone un modello di classificazione dei segnali stradali basato su una rete neurale convoluzionale (CNN) denominata **MiniAlexNetV2**. Il modello classifica i segnali in quattro macrocategorie: *Indicazione*, *Pericolo*, *Divieto* e *Background*. Partendo dall'architettura AlexNet, sono state introdotte *Batch Normalization* e *Dropout* per stabilizzare l'addestramento e ridurre l'overfitting. La configurazione ottimale (Learning Rate 0.003, Momento 0.6, 200 epoche) raggiunge un'accuratezza di test del 85-90% con curve ROC che mostrano un'ottima capacità discriminante ($TPR \approx 1.0$ per $FPR \approx 0.2$). Il lavoro costituisce una base solida per sviluppi futuri verso il riconoscimento del singolo segnale.

Problema

Il problema affrontato è il **riconoscimento automatico dei segnali stradali**, requisito essenziale per i sistemi di guida autonoma e assistenza alla guida (ADAS). In scenari reali i segnali appaiono in condizioni eterogenee (illuminazione variabile, occlusioni parziali, diverse condizioni meteorologiche) e appartengono a categorie eterogenee (limiti di velocità, divieti, obblighi, avvisi).

L'obiettivo è sviluppare un classificatore basato su CNN in grado di:

- Distinguere i segnali stradali dallo sfondo (classe *Background*);
- Classificare correttamente i segnali rilevati in tre macrocategorie semantiche: *Indicazione*, *Pericolo*, *Divieto*;
- Raggiungere un'accuratezza sufficientemente elevata per un impiego affidabile in contesti reali;
- Bilanciare capacità di apprendimento e generalizzazione, contenendo l'overfitting.

Il dataset utilizzato (sottoinsieme GTSRB, ~450 MB, ~50.000 immagini) è stato riorganizzato da 43 classi specifiche alle 4 macrocategorie sopra indicate.

Metodo Utilizzato

Architettura di Rete: MiniAlexNetV2

Partendo da **AlexNet**, sono state sviluppate due evoluzioni progressive:

1. **MiniAlexNet**: versione alleggerita di AlexNet con riduzione del numero di filtri e parametri;
2. **MiniAlexNetV2**: aggiunta di **Batch Normalization** (dopo ogni layer convoluzionale e fully-connected) e **Dropout** ($p=0.5$ nei layer fully-connected) per stabilizzare l'addestramento e regolarizzare il modello.

L'architettura finale comprende: 5 layer convoluzionali con ReLU, MaxPooling (kernel 2, stride 1), 3 layer fully-connected, e classificazione finale a 4 classi con Softmax.

Funzione di Loss e Ottimizzazione

- **Loss:** Cross Entropy Loss (multiclasse a 4 classi).
- **Ottimizzatore:** SGD con Momentum.
- **Input:** Immagini ridimensionate, batch size 1024 (train) / 2048 (val/test).
- **Data Augmentation:** Normalizzazione, resize, eventuale augmentazione geometrica.

Selezione degli Iperparametri

È stata condotta una **grid search** su 9 combinazioni:

- Learning Rate: {0.0001, 0.001, 0.003}
- Momentum: {0.3, 0.6, 0.9}

Addestramento a 200 epoche per ogni configurazione, con estensione a 1200 epoche per la configurazione migliore. Metriche monitorate: Accuracy (train/test), Loss (train/test), Curve ROC per classe.

Metriche di Valutazione

- **Accuracy:** $\frac{\text{Previsioni Corrette}}{\text{Totale Previsioni}}$ da matrice di confusione 4x4.
- **Curve ROC / AUC:** Analisi TPR vs FPR per classe al variare della soglia.
- **Gap Train-Test:** Indicatore di overfitting.

Risultati

Confronto Architetture (LR=0.001, Mom=0.6, 200 epoche)

- **AlexNet:** Acc $\approx$ 0.3-0.4, Loss elevata (1.5-4.5), ROC $\approx$ caso casuale $\rightarrow$ scarsa generalizzazione.
- **MiniAlexNet:** Acc $\approx$ 0.48-0.56, Loss stabili, ROC $\approx$ caso casuale $\rightarrow$ buona generalizzazione ma capacità limitata.
- **MiniAlexNet V2:** Acc $\approx$ 0.6-0.8, Loss 0.5-1.0, ROC nettamente sopra la diagonale $\rightarrow$ **miglior compromesso capacità/generalizzazione.**

Ottimizzazione Iperparametri su MiniAlexNet V2

- **LR 0.0001:** Fallimentare per tutti i momenti (Acc $\approx$ 0.1-0.2).
- **LR 0.001:** Risultati intermedi; best a Mom 0.9 (Acc $\approx$ 0.7-0.8) ma con overfitting.
- **LR 0.003:** **Migliori risultati;** best a **Mom 0.6** (Train Acc $>$ 0.9, Test Acc $\approx$ 0.8, Loss train $\approx$ 0.5, test $\approx$ 0.8-1.0, ROC eccellenti).

Configurazione Ottimale Selezionata

Parametro	Valore
Learning Rate	0.003
Momentum	0.6
Epoches	200 (estendibile a 1200)
Batch Size (train/val)	1024 / 2048
Architettura	MiniAlexNetV2

Addestramento Prolungato (1200 epoche, LR=0.003, Mom=0.6)

- Train Acc $\rightarrow$ 1.0 già a $\sim$ 400 epoche; Test Acc si stabilizza a **0.85-0.90**.
- Train Loss $\rightarrow$ 0.0; Test Loss $\rightarrow$ 0.5-1.0 (leggero aumento tardivo).
- Curve ROC: TPR = 1.0 per FPR $\approx$ 0.2-0.3 su tutte e 3 le classi principali $\rightarrow$ **eccellente separazione**.
- Gap train-test costante $\rightarrow$ overfitting presente ma non peggiorante nel tempo.
- Conclusione: 200 epoche sufficienti; 1200 epoche danno guadagno marginale.

Conclusione

Il lavoro dimostra che **MiniAlexNetV2** con LR=0.003, Momentum=0.6 risolve efficacemente la classificazione a 4 macrocategorie di segnali stradali (Test Acc 85-90%, ROC eccellenti). L'overfitting residuo è gestibile e non peggiora con epoch addizionali.

Sviluppi Futuri

1. **Aumento e diversificazione del dataset:** Più immagini, condizioni meteo/illuminazione variata, data augmentation avanzata (CutMix, MixUp, Albumentations) per migliorare generalizzazione.
2. **Architetture alternative:** Sperimentare ResNet, EfficientNet, MobileNetV3, Vision Transformers (ViT) per confrontare parametri/accuratezza/latency.
3. **Regolarizzazione avanzata:** Label Smoothing, Weight Decay più aggressivo, Stochastic Depth, MixUp per ridurre ulteriormente l'overfitting.
4. **Ottimizzazione iperparametri estesa:** Learning rate scheduling (Cosine Annealing, OneCycleLR), Bayesian Optimization / Optuna per LR, Momentum, Weight Decay, Batch Size.
5. **Quantizzazione e Deployment:** Post-training quantization (INT8), TensorRT/ONNX Runtime per inferenza real-time su edge device (Jetson, Raspberry Pi).
6. **Analisi interpretabilità:** Grad-CAM, feature visualization, attention maps per capire cosa impara la rete per classe.

7. **Evoluzione del task:** Passaggio da **classificazione a 4 macrocategorie** a **classificazione fine-grained (43+ classi GTSRB)** e **object detection end-to-end** (YOLOv8/v11, RT-DETR) per detection + classification in un solo stadio.
8. **Test su dati reali estesi:** Validazione su dataset reali completi (es. Mapillary Traffic Sign, BDD100K, dataset proprietari automotive) per misurare il domain gap.

In sintesi, il lavoro costituisce una **baseline solida e riproducibile** per il riconoscimento dei segnali stradali, con un'architettura leggera, ben regolarizzata e iperparametri validati sperimentalmente, pronta per essere estesa verso scenari più complessi e deployment reale.